Universo Visual y Preparación del Dataset

Sprites CC0 de mazmorra procesados a 64×64 con filtrado y aumento ×12

DEFINICIÓN DEL UNIVERSO VISUAL

- **Estilo y Estética:** *Dungeon crawler* clásico en pixel art retro. Sprites con paleta limitada de colores, contornos perimetrales oscuros y fondo plano negro/oscuro.
- **Morfología esperada:** Siluetas compactas, masas corporales redondeadas antropomorfas y criaturas místicas con alto contraste figura-fondo.

ORIGEN Y PREPROCESAMIENTO DE DATOS

- **Fuentes (Licencia CC0 - Dominio Público):**
  - *Tiny Dungeon* por Kenney (opengameart.org/content/tiny-dungeon)
  - *Tiny Creatures* por Clint Bellanger (opengameart.org/content/tiny-creatures)
- **Limpieza:** 312 sprites extraídos → **filtrado manual estricto a 200 originales** de 16×16 eliminando muros, armas y objetos inertes.
- **Normalización:** Padding simétrico a cuadrado, reescalado a 64×64 mediante interpolación **NEAREST** (preservando el filo del píxel) y normalización a [-1, 1].
- **Aumento ×12:** Volteo horizontal × 6 permutaciones de canales RGB → **2,400 imágenes** finales de entrenamiento.

LIMITACIONES DECLARADAS

Dataset reducido (200 originales); persistencia de algunos objetos residuales; las permutaciones de canal introducen tonalidades fuera de la paleta original del autor.

MUESTRA DE SPRITES REALES EN data64/ (64×64)

Rejilla 4×4 de sprites procesados con fondo negro e interpolación NEAREST

Diseño de la Arquitectura DCGAN 64×64

Fundamento teórico de convoluciones transpuestas, normalización y logits

JUSTIFICACIÓN DE LA ARQUITECTURA

• **Selección:** DCGAN profunda adaptada a 64×64, elegida por ser el estándar canónico en síntesis adversarial convolucional, altamente interpretable y eficiente en CPU.

ESPECIFICACIÓN DE MÓDULOS

• **Generador (G):** Vector latente $z \in R^{100}$ proyectado mediante 5 etapas de *ConvTranspose2d* (512 → 256 → 128 → 64 → 3) con BatchNorm2d y activaciones ReLU. Capa final con activación **Tanh** escalando la salida a [-1, 1].

• **Discriminador (D):** 5 etapas convolucionales *Conv2d* (3 → 64 → 128 → 256 → 512 → 1) con activaciones **LeakyReLU(0.2)**. Normalización con BatchNorm2d (control y hinge) o Spectral Norm sin BN (experimento SN).

DECISIONES TÉCNICAS DE CONTROL

• **Salida en Logits:** D no incluye capa Sigmoid final; devuelve directamente logits en R. En la base se emplea BCEWithLogitsLoss, matemáticamente idéntica pero numéricamente estable y obligatoria para desacoplar D y permitir la pérdida Hinge.

• **Hiperparámetros fijos:** Optimizador Adam (lr = 2e-4, β■ = 0.5, β■ = 0.999), batch size = 64, 60 épocas, semilla global 42 y ruido fijo de control con semilla 123.

DIAGRAMA DE FLUJO: GENERADOR Y DISCRIMINADOR

Flujo de capas: Convoluciones transpuestas en G y convoluciones strided en D

Pérdida Adversarial: BCE (Base) vs. Hinge Loss

Evaluación de márgenes lineales frente a la saturación de la sigmoide

HIPÓTESIS A PRIORI (REGISTRADA)

"Creemos que la función hinge mejorará la estabilidad y calidad visual porque penaliza únicamente las muestras que violan el margen y proporciona gradientes lineales no saturantes al generador, a diferencia de BCE donde la sigmoide tiende a saturarse cuando D toma ventaja. Lo consideraremos útil si las curvas muestran mayor estabilidad y las muestras exhiben siluetas más definidas y menor ruido."

CONTROL Y DINÁMICA OBSERVADA

- **Control estricto:** Mismos datos, pesos iniciales (seed 42), 60 épocas y ruido fijo.
- **Modelo Base (BCE):** D dominó persistentemente (D(x) 0.87–0.97, D(G(z)) 0.03–0.14) provocando pérdidas elevadas e inestables en G (4.0–6.0).
- **Modelo Hinge:** Pérdida de G significativamente más acotada y suave (2.6–3.3). No obstante, la pérdida de D cayó a 0.02–0.06 entre las épocas 30 y 55 (zona de alarma por sobreoptimización de margen).
- **Diversidad (Distancia media en 256 muestras):** Reales: 0.350 | Base: 0.331 | **Hinge: 0.333** (+0.0025 a favor de Hinge).

CONCLUSIÓN HONESTA

Hinge reduce visualmente los bloques blancos inconexos. Sin embargo, la ventaja numérica (+0.0025) al provenir de una única corrida no es concluyente.

COMPARATIVA VISUAL Y SALIDAS D(x) / D(G(z))

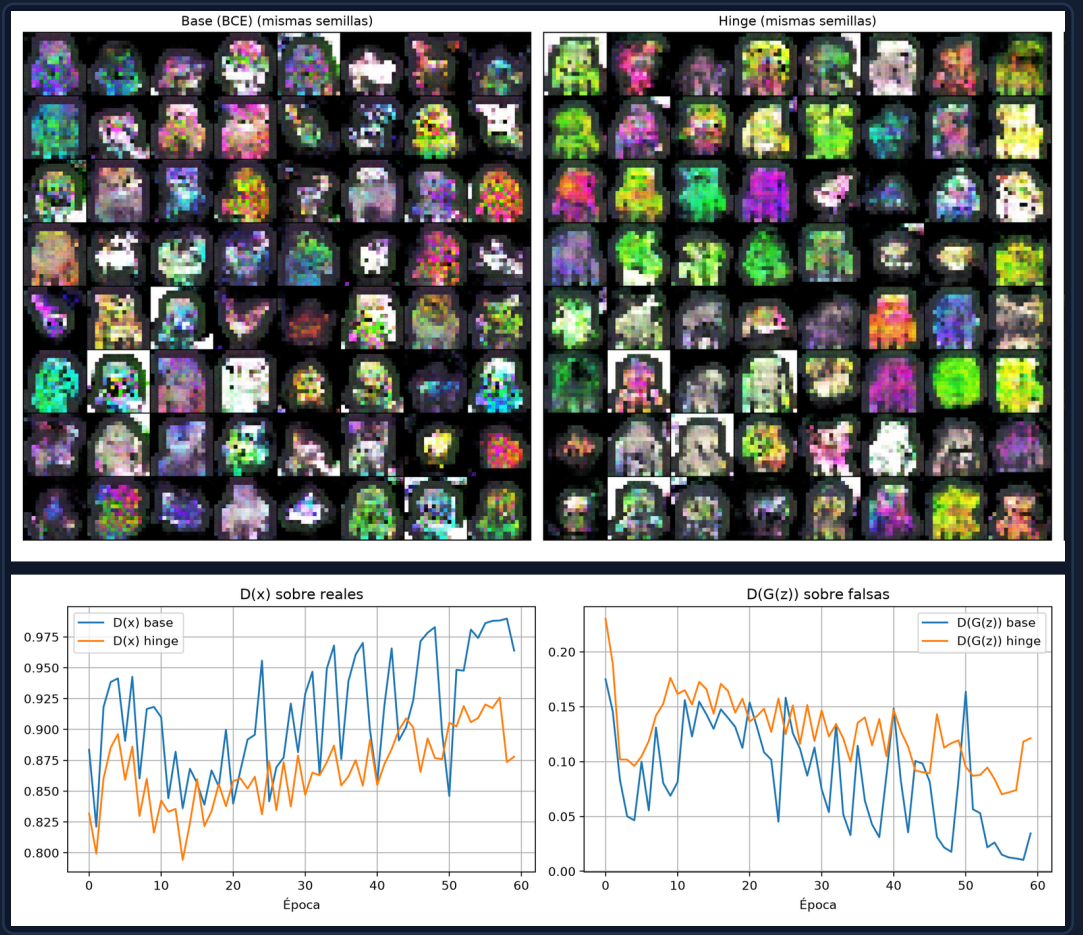

Superior: Muestras Base vs Hinge. Inferior: Probabilidades de salida de D

Estabilización con Spectral Normalization en D

Análisis de la restricción de Lipschitz y el impacto de retirar BatchNorm

HIPÓTESIS A PRIORI

"Creemos que mejorará porque Spectral Normalization acota la constante de Lipschitz de cada capa convolucional del discriminador (limitando la norma espectral de los pesos), controlando los gradientes que recibe G y previniendo dominancia prematura sin depender de BatchNorm. Lo consideraremos útil si el entrenamiento se mantiene estable y genera siluetas estructuradas."

CAVEAT METODOLÓGICO Y RESULTADOS

- **Factor de confusión:** Al implementar SN se retiró *BatchNorm2d* en D. Por ende, variaron dos componentes simultáneamente (SN + omisión de BN).
- **Dinámica de pérdidas:** Curvas extraordinariamente equilibradas en papel: D osciló en 0.7–0.9 y G en 1.5–2.0 a partir de la época 20.
- **Falla en calidad visual:** Pese a curvas ideales, las imágenes generadas resultaron sumamente oscuras, descoloridas y con contornos deficientes.
- **Colapso de diversidad:** Registró la diversidad más baja de todas: **0.268** (vs 0.333 en Hinge y 0.350 en datos reales).

LECCIÓN METODOLÓGICA

SN no mejoró los resultados. La ausencia de normalización por lotes en D perjudicó severamente la propagación de gradientes útiles hacia el generador.

COMPARACIÓN DE LOS 3 MODELOS Y CURVAS SN

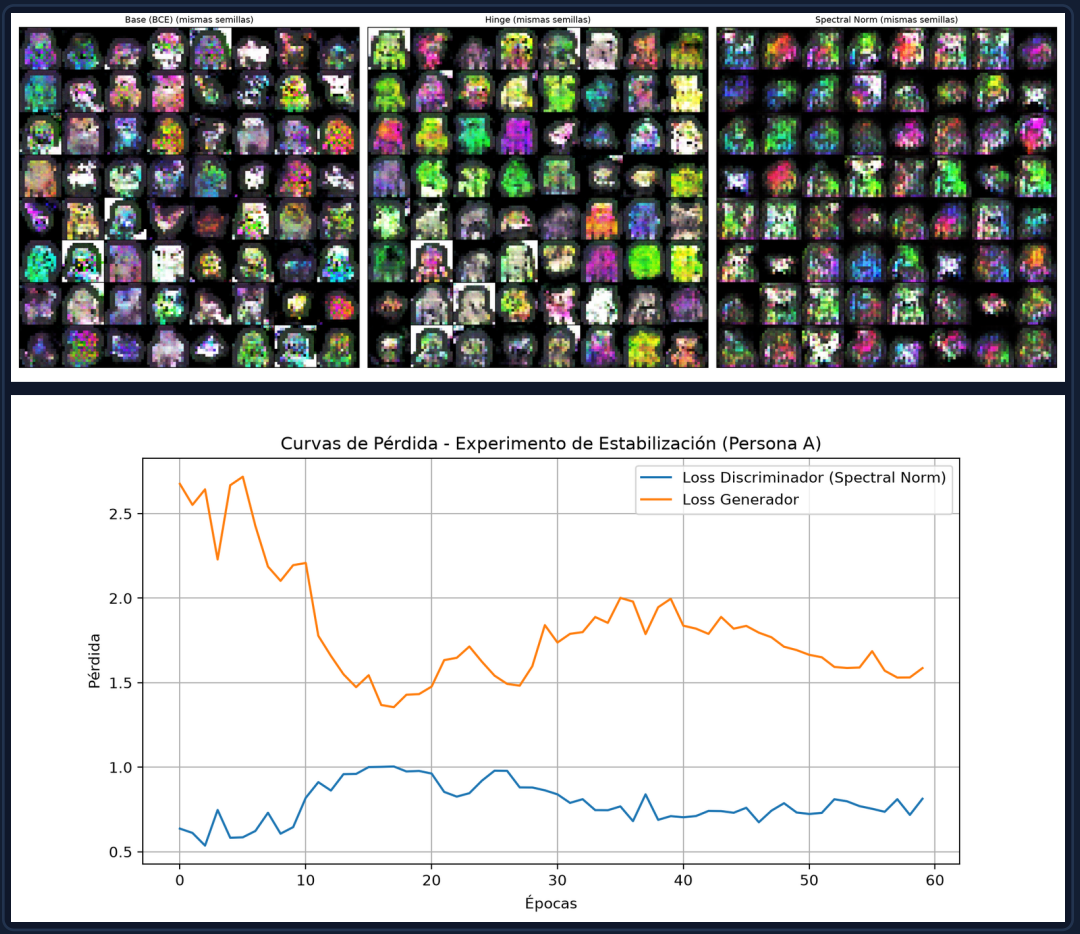

Superior: Rejilla Base vs Hinge vs Spectral. Inferior: Curvas de pérdida de SN

Monitoreo con Ruido Fijo (Épocas 1 a 60)

Trayectoria de los mismos 16 vectores z fijos (semilla 123) en el modelo Hinge

ANÁLISIS DE LA TRAYECTORIA GENERATIVA

• **Metodología:** Se evaluaron exactamente los mismos 16 vectores z fijos (guardados en checkpoints/fixed_noise.pt) a lo largo del entrenamiento para aislar la evolución de los pesos.

DESGLOSE POR ETAPAS CLAVE

• **Época 1 (Ruido estocástico):** Patrones totalmente difusos sin noción de simetría ni límites geométricos.

• **Épocas 5–10 (Colapso parcial temprano):** Fenómeno transitorio común en DCGAN; las 16 columnas reproducen prácticamente la misma textura repetitiva.

• **Épocas 20–30 (Bifurcación y ruptura):** El optimizador rompe la trampa del colapso; las columnas se diferencian cromáticamente y emergen siluetas centradas.

• **Época 60 (Estado final):** 16 entidades individuales distinguibles con contorno oscuro perimetral y fondo negro bien segmentado.

HALLAZGO PRINCIPAL

La red no sufrió colapso modal definitivo: demostró capacidad de autorrecuperación tras las épocas críticas tempranas.

EVOLUCIÓN TEMPORAL: REJILLA DE RUIDO FIJO (HINGE)

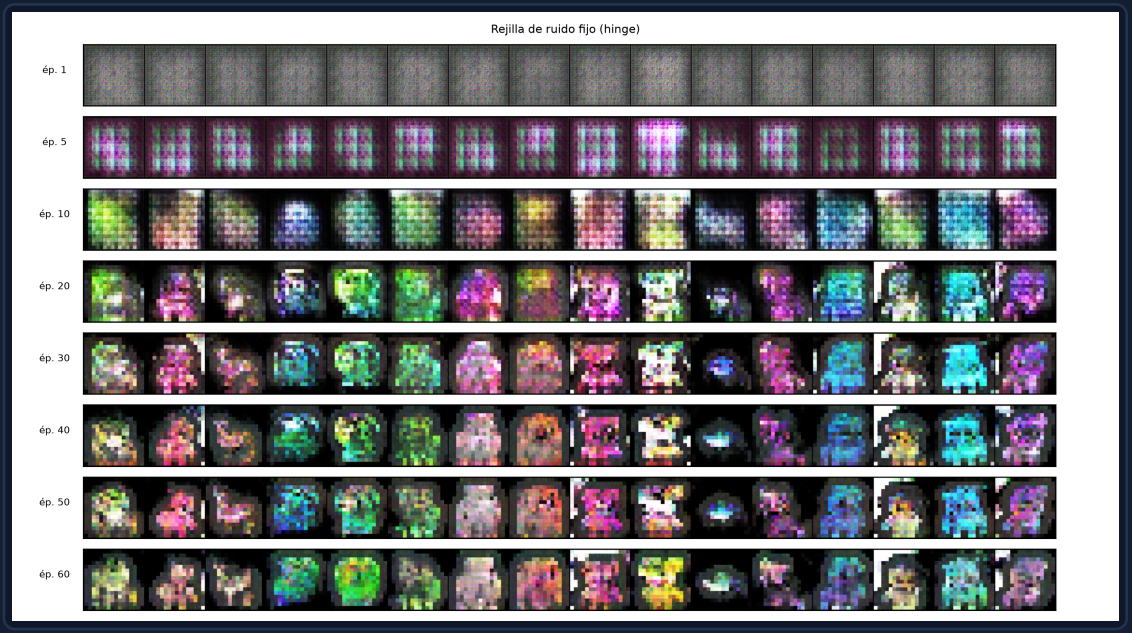

Columnas = Mismos 16 vectores latentes fijos evaluados en épocas 1, 5, 10, 20, 30, 40, 50 y 60

Interpretación Crítica de las Curvas de Pérdida

Por qué el equilibrio numérico de las curvas no garantiza calidad perceptual

COMPARACIÓN DE DINÁMICAS ADVERSARIALES

- **Spectral Norm (Equilibrio teórico ideal):** G desciende de ~2.7 a ~1.4 hacia la época 15 mientras D asciende a ~1.0, manteniéndose enfrentadas en perfecto equilibrio. *Paradoja: Fue el mejor en curvas pero el peor en calidad visual.*
- **Base BCE (Dominio sostenido de D):** Probabilidades D(x) cercanas a 1 y D(G(z)) cercanas a 0. Pérdida de G estancada en valores altos (4.0–6.0). El discriminador aprendió mucho más rápido.
- **Hinge Loss (Pérdida de G estable con zona de alarma):** G mantiene una trayectoria sumamente controlada (2.6–3.3). Sin embargo, la pérdida de D cae a valores cercanos a 0 en épocas 30–55 debido a que las muestras sobrepasaron el margen (+1 / -1).

LECCIÓN FUNDAMENTAL PARA GANs

En entrenamiento adversarial, las curvas de pérdida no son funciones monótonas de convergencia. El equilibrio numérico no implica alta fidelidad visual, y las pérdidas entre BCE y Hinge no son comparables directamente en magnitud.

CURVAS DE ENTRENAMIENTO (BASE vs HINGE vs SN)

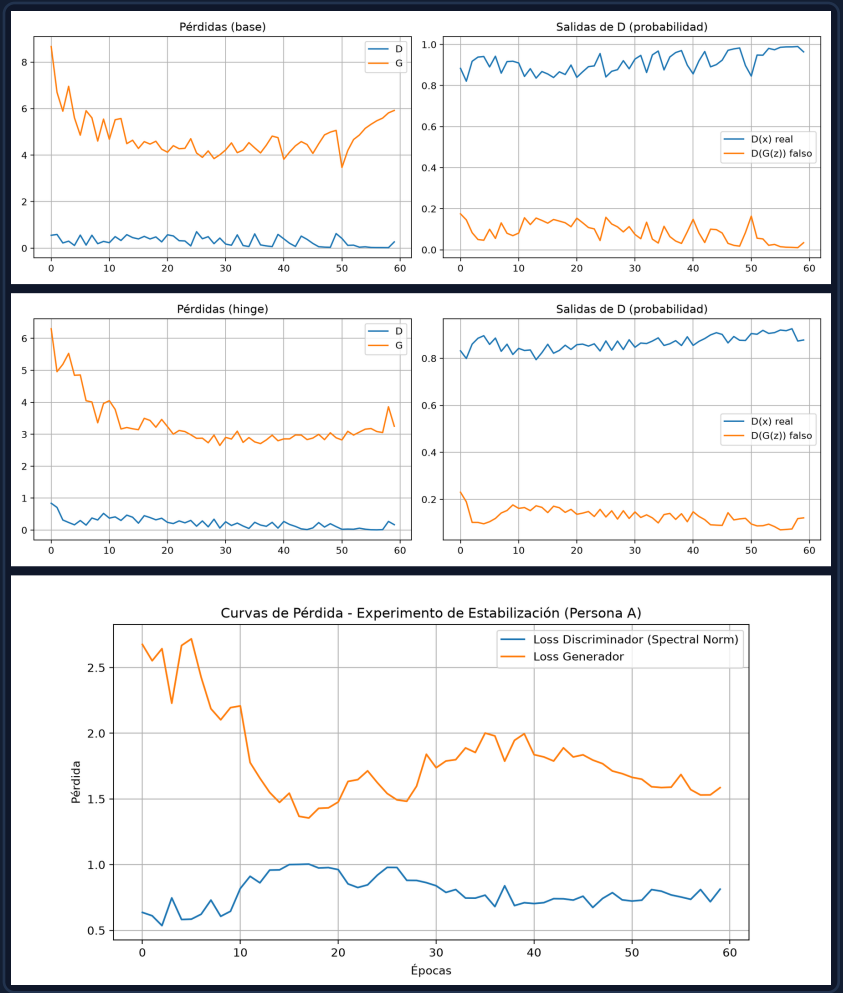

De arriba a abajo: Pérdidas de Base (BCE), Hinge Loss y Spectral Norm

Problemas Encontrados y Decisiones Técnicas

Desafíos de calibración, filtrado y limitaciones computacionales

DESAFÍOS TÉCNICOS Y SOLUCIONES ADOPTADAS

1. **Galería basura en modo eval:** En inferencia, netG.eval() producía rejillas idénticas sin textura. *Causa:* Estadísticas de lote de BatchNorm descalibradas. *Solución:* Se implementó recalibrate_bn() pasando 50 lotes de ruido sintético antes de generar.
2. **Contaminación del dataset:** Los sprites originales incluían muros, armas y cofres. Se filtró manualmente de 312 a 200, aunque persistieron algunos artefactos.
3. **Colapso parcial temprano (épocas 5–10):** Resuelto espontáneamente por la dinámica del optimizador Adam hacia la época 25–30.
4. **Distorsión cromática en data augmentation:** Las permutaciones RGB generaron tonos fluorescentes ajenos a la paleta clásica de Kenney.
5. **Sesgo en métrica de vecinos (ResNet-18):** Redimensionar a 16×16 provocó que la red agrupara por fondo negro y color, no por morfología corporal.
6. **Restricción de cómputo en CPU:** Acotado a 60 épocas; la inspección visual sugiere que con mayor tiempo las siluetas continuarían refinándose.

EVIDENCIA: COLAPSO TEMPRANO VS RECUPERACIÓN

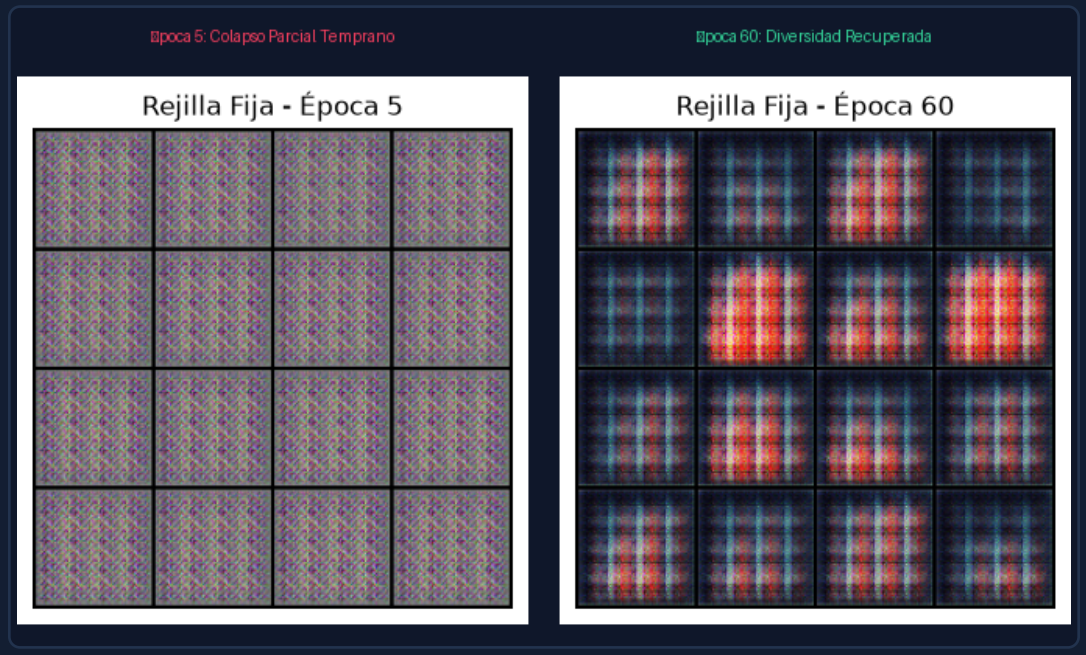

Comparativa de muestras en época 5 (colapso transitorio) vs época 60 (diversidad recuperada)

Galería Final de Personajes (Modelo Hinge)

Tasa de selección del 5%, criterio de curación honesto y regenerabilidad 100%

PROTOCOLO DE SELECCIÓN Y CURACIÓN

- **Tasa de selección: 10 seleccionados de 200 candidatos (5.0%)**, sintetizados por el modelo Hinge con semillas 1000 + índice.
- **Índices elegidos:** [4, 14, 29, 45, 64, 104, 110, 112, 154, 184].

CRITERIO DE CURACIÓN (HONESTO Y MODESTO)

"Se eligieron muestras con silueta central perceptible y contraste claro frente al fondo negro, que evitaran manchas amorfas o exceso de ruido disperso, buscando cubrir variedad de tonos (verdes, cálidos, celestes, blancos) y posturas dentro del nivel de definición alcanzado por el modelo."

VERIFICACIÓN DE REGENERABILIDAD

Cada personaje se regenera de forma idéntica desde su vector z guardado (personaje_XX_z.pt) y los pesos netG_hinge.pth con error absoluto máximo ≤ **0.00196** (asociado estrictamente al redondeo de 8 bits al serializar en PNG).

BONIFICACIÓN DE LORE

Cada criatura posee nombre y rol asignado en el universo (ej. Morvath, Ignis, Grog, Zul'Karr, Glacius, Ursok).

MOSAICO DE LOS 10 PERSONAJES ELEGIDOS

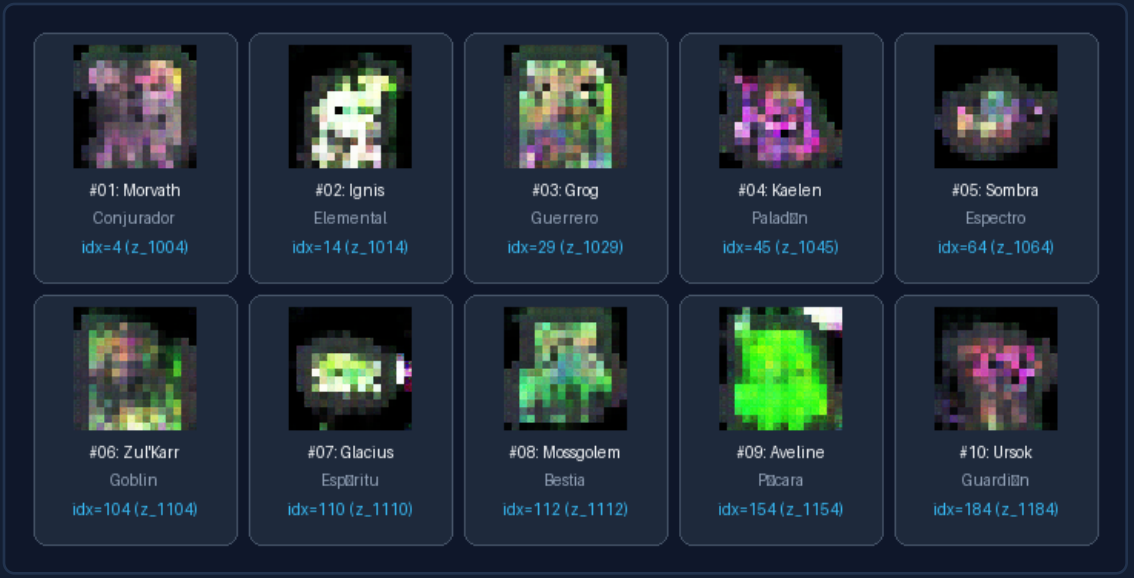

Los 10 personajes seleccionados con su nombre de lore, clase y semilla z asociada

Análisis de Vecinos Más Cercanos: Originalidad

Evaluación de memorización: Espacio latente ResNet-18 vs. Distancia en píxeles (RMS)

EVALUACIÓN DE MEMORIZACIÓN VS. SÍNTESIS

Para cada personaje generado se buscó su ejemplar más cercano dentro de los 200 sprites originales del dataset.

MÉTRICA 1: RESNET-18 (SIMILITUD COSENO)

- Similitudes obtenidas: 0.73–0.88 (frente a 0.974 entre sprites reales).
- **Sesgo del embedding:** 6 de los 10 personajes se emparejaron con el mismo sprite de un objeto apilado, demostrando que la red preentrenada fue dominada por el color de fondo y textura.

MÉTRICA 2: ESPACIO DE PÍXELES (RMS)

- Distancias RMS obtenidas: **0.14–0.27**.
- Emparejó correctamente con criaturas vivas (conejos, ranas, osos, peces).
- *Caveat:* El RMS más bajo (#5 con 0.136) es artificial por predominar píxeles negros tanto en la muestra como en el sprite real.

CONCLUSIÓN DE ORIGINALIDAD

Ningún personaje es copia de su vecino. Los más cercanos a simple vista son el #8 (oso verde) y el #10 (oso café).

COMPARATIVA 1 A 1 CON VECINO MÁS CERCANO (RMS)

Pares generados vs vecino de entrenamiento más próximo en distancia RMS

Conclusiones y Limitaciones del Proyecto

Síntesis del rendimiento experimental y honestidad sobre el alcance alcanzado

CONCLUSIONES PRINCIPALES

- **Formación de siluetas:** Tanto el modelo Base (BCE) como Hinge sintetizan satisfactoriamente siluetas y masas centradas con contornos perimetrales reconocibles en 64×64.
- **Spectral Normalization:** Su implementación sin BatchNorm deterioró drásticamente la estructura visual y luminosidad, pese a mostrar curvas teóricamente ideales.
- **Hinge vs Base:** La ventaja de Hinge fue marginal (+0.0025 en diversidad) y cualitativa (menor ruido disperso), no estadísticamente concluyente con una corrida.
- **Ausencia de colapso de modo final:** 16 vectores fijos sintetizan 16 criaturas morfológicamente diferentes a la época 60.
- **No memorización:** Ningún personaje copió píxeles de entrenamiento (RMS 0.14–0.27); la red aprendió combinaciones de patrones.

LIMITACIONES METODOLÓGICAS

- **Escasez de datos y épocas:** Solo 200 sprites originales de 16×16 y 60 épocas en CPU. La red aún no alcanzaba una meseta completa.
- **Contaminación del dataset:** Permanencia involuntaria de algunos objetos inanimados en el conjunto filtrado.
- **Paleta distorsionada por aumento:** Las permutaciones RGB generaron colores no canónicos en el universo medieval.
- **Factor de confusión en SN:** Reemplazar BatchNorm por Spectral Norm impidió aislar con precisión la causa de la degradación.
- **Semilla única:** Falta de intervalos de confianza por restricciones de tiempo de entrenamiento en CPU.
- **Resolución semántica:** Los personajes son sugerencias impresionistas y siluetas; no sprites con rasgos faciales acabados.

Reflexión Final: ¿Qué Aprendió Realmente la GAN?

Caso de estudio de los personajes #8 y #10 frente a criaturas de entrenamiento

PREGUNTA DE INVESTIGACIÓN ORIENTADORA

"¿Cuál de sus 10 personajes le costó más defender como 'nuevo' frente a su vecino más cercano? ¿Qué dice sobre lo que aprendió la GAN?"

CASOS DE ESTUDIO CRÍTICOS (#8 Y #10)

- En métrica matemática pura (ResNet-18), el personaje #2 arrojó similitud 0.878, pero fue emparejado erróneamente con un objeto debido al sesgo de fondo.
- A nivel visual humano, los personajes **#8 (Mossgolem)** y **#10 (Ursok)** fueron los más complejos de defender: comparten la distribución de masa y paleta específica con el **oso verde** y el **oso café** del dataset original.

¿QUÉ APRENDIÓ REALMENTE LA RED?

- **Aprendió el lenguaje de estilo global:** Distribución de masa centrada, contorno perimetral oscuro con halo grisáceo, fondo negro uniforme y lógica de bloques de píxel art.
- **No aprendió el dibujo fino ni memorizó:** No fue capaz de recrear ojos detallados, armaduras nítidas ni extremidades complejas. La GAN actúa como un pintor impresionista que reproduce la atmósfera y silueta del género sin dominar los detalles anatómicos.

CASO DE ESTUDIO: PERSONAJES #8 Y #10 VS VECINOS

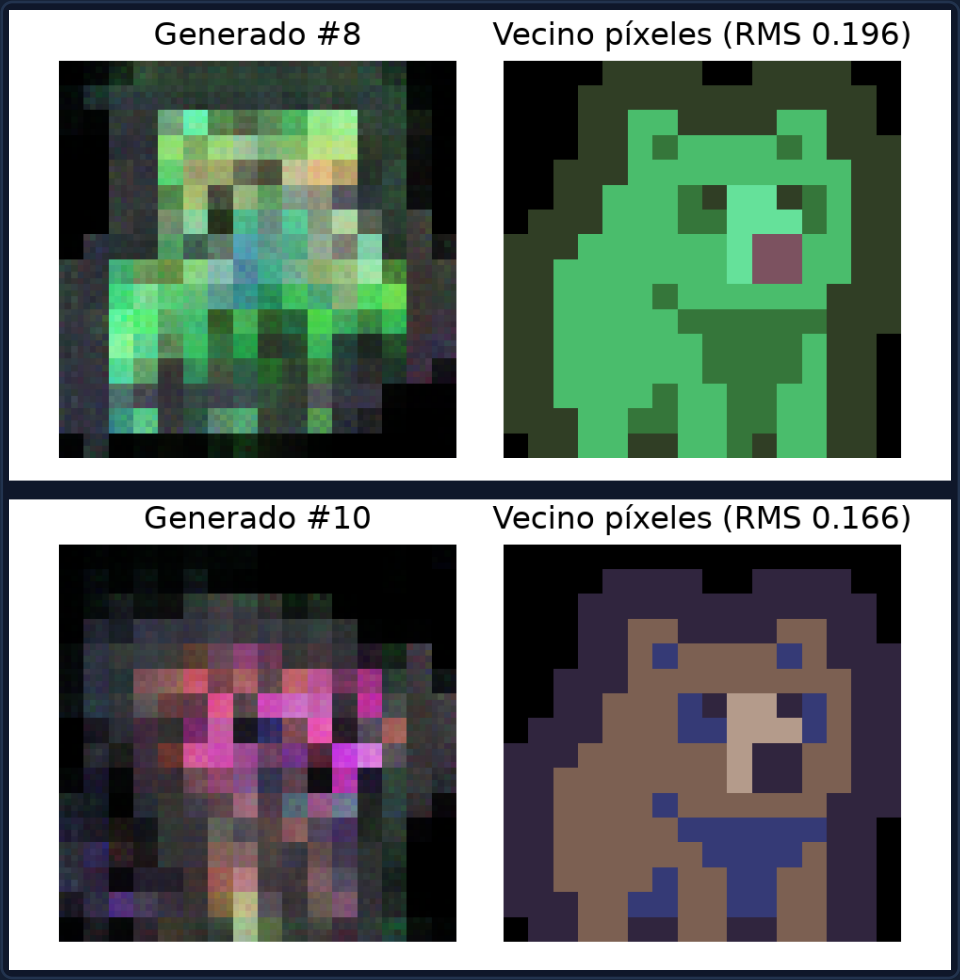

Fila superior: Personaje #8 frente a Oso Verde. Fila inferior: Personaje #10 frente a Oso Café

Matriz Completa de Evidencias Experimentales

Resumen cruzado de cada sección, conclusiones derivadas y limitaciones metodológicas

Evidencia	Slide	Conclusión Derivada	Limitación Declarada
Universo y datos CC0	1	200 sprites limpios (Kenney, Bellanger) aumentados a 2,400.	Dataset reducido; objetos residuales; colores del aumento fuera de paleta.
Arquitectura DCGAN	2	Modelo estándar 64×64 interpretable y ejecutable en CPU.	Sin mecanismos de atención ni arquitecturas modernas.
Experimento Hinge vs BCE	3	Hinge estabiliza G; diversidad 0.333 vs 0.331; D cae a 0 en épocas 30-55.	Diferencia mínima (+0.0025); una sola corrida no concluyente.
Experimento Spectral Norm	4	SN no mejoró; curvas perfectas pero imágenes oscuras (div 0.268).	SN reemplazó BatchNorm alterando dos factores a la vez.
Rejilla de ruido fijo	5	Colapso parcial temprano superado hacia la época 30.	Imágenes finales aún presentan ruido y falta de nitidez.
Curvas de pérdida	6	El equilibrio en pérdidas no equivale a calidad generativa.	BCE y Hinge operan en escalas no comparables directamente.
Problemas y decisiones	7	Modo eval corregido mediante recalibrate_bn; filtrado manual.	Entrenamiento limitado a 60 épocas por tiempo de CPU.
Galería de 10 personajes	8	Tasa 5% (10 de 200); regenerabilidad idéntica verificada (≤0.00196).	Ningún personaje es completamente acabado; selección subjetiva.
Vecinos más cercanos	9	Ningún personaje es copia memorizada (RMS 0.14–0.27).	ResNet-18 sesgado por fondo negro y textura a 16×16.
Conclusiones y límites	10	La GAN aprendió la distribución espacial sin memorizar.	Restricción de cómputo y falta de réplicas estadísticas.
Reflexión final	11	La red aprendió el estilo global, no el detalle anatómico fino.	Conclusión basada en el análisis cualitativo de 10 muestras.