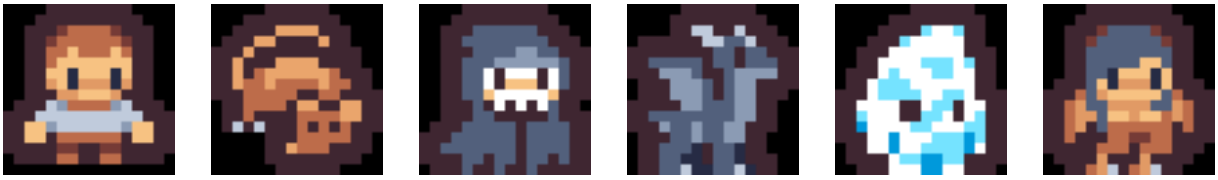
Universo visual y datos

Referencia: Proyecto 2, Diseño generativo de personajes
Entidad destinataria: Universidad del Valle de Guatemala, Deep Learning 2026
Objeto: Generación de conceptos visuales mediante una GAN
Tipo de documento: Informe de resultados en 12 páginas
Autores: Luis Gonzalez - 23353 y Jonathan Zacarias - 231104
Docente: Kevin Recinos
Fecha: 11 de octubre de 2026

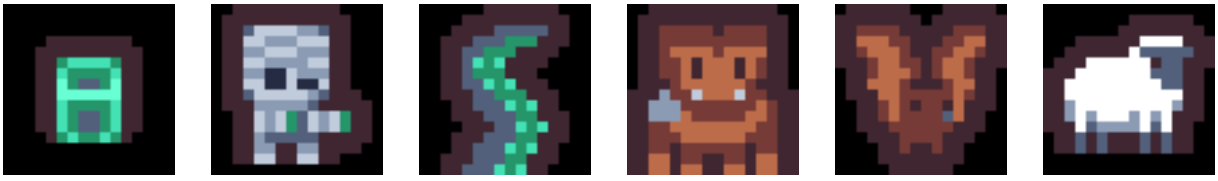
Nuestro universo reúne habitantes de criptas, cavernas y ruinas: aventureros, criaturas y guardianes. Buscamos pixel art de baja resolución, figuras compactas, contornos oscuros y una paleta reducida. Juzgamos los resultados por la legibilidad de su silueta y su variedad visual. Los nombres y roles de la galería son interpretaciones humanas de los conceptos generados.

El archivo suministrado contiene 312 sprites de 16 × 16: 132 de Tiny Dungeon, de Kenney, y 180 de Tiny Creatures, de Clint Bellanger con colaboración de Kenney. Las páginas de origen declaran licencia CC0. La revisión conserva 199 imágenes y registra la decisión de cada archivo en un manifiesto.

Fuentes: kenney.nl/assets/tiny-dungeon y opengameart.org/content/tiny-creatures.



d0085 d0123 c0020 c0033 c0050 c0068



c0083 c0096 c0113 c0126 c0139 c0154

Depuración, separación y aumento de datos

La revisión visual elimina 112 piezas de escenarios, objetos, armas, equipo e interfaz de Tiny Dungeon, además de una mano aislada de Tiny Creatures. Aceptamos criaturas completas, incluidos monstruos vegetales y animales. La comprobación de contenido y su reflejo no encontró duplicados exactos entre las imágenes aceptadas.

Etapa	Cantidad	Tratamiento
Archivos originales	312	PNG legibles de 16 × 16
Sprites aceptados	199	20 de Dungeon y 179 de Creatures
Entrenamiento	164	102 grupos de familias
Validación	35	26 grupos reservados
Entrenamiento aumentado	328	Original y reflejo horizontal

Agrupamos variantes conocidas de color, tamaño y pose, junto con siluetas exactamente iguales incluso reflejadas. La semilla 1729 asigna aproximadamente el 20% de grupos a validación antes del aumento. Ningún grupo aparece en ambas particiones. Esta regla reduce la fuga de variantes conocidas, aunque la clasificación manual puede omitir parentescos visuales.

Componemos la transparencia sobre negro, centramos la caja de contenido en 16 × 16 y escalamos con NEAREST a 64 × 64. Normalizamos RGB a [-1, 1]. Eliminamos las permutaciones RGB. La validación conserva sus imágenes originales y nunca participa en los gradientes.

Las siguientes imágenes pertenecen exclusivamente a validación:


d0084


d0109


d0110


d0111


d0121


c0002

Arquitectura y aprendizaje adversarial

Elegimos una DCGAN compacta porque los datos tienen estructura espacial y una resolución nativa de solo 16 × 16. Aprender esa rejilla evita dedicar capacidad a los bloques repetidos que introduce el escalado a 64 × 64. La exportación NEAREST forma parte del generador y mantiene bloques de 4 × 4 uniformes.

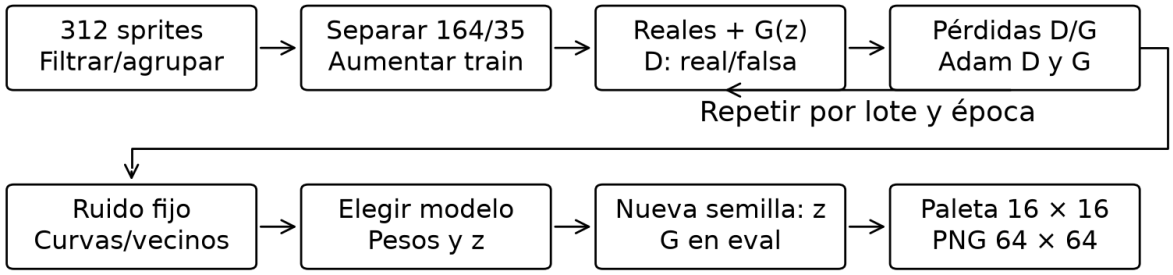
El generador recibe z de 100 números normales. Tres convoluciones transpuestas construyen mapas de 4 × 4 con 256 canales, 8 × 8 con 128 canales y 16 × 16 con 23 canales. Las dos primeras etapas usan BatchNorm y ReLU. La red tiene 981760 parámetros. D promedia bloques de 4 × 4 para reducir a 16 × 16; usa convoluciones 3/64/128/1, LeakyReLU y BatchNorm. Devuelve una puntuación sin Sigmoid final y tiene 136448 parámetros.

La salida final asigna a cada píxel uno de los 23 colores presentes en entrenamiento. El pase hacia adelante usa argmax. Para aprender a través de esa selección discreta, usamos un gradiente sustituto de softmax, denominado straight-through. En evaluación la selección es determinista. Esta aproximación introduce sesgo en el gradiente y constituye una limitación del diseño.

Por lote, D evalúa imágenes reales y falsas y Adam ajusta sus parámetros. Después evaluamos las falsas con D actualizado y retropropagamos hasta G; Adam actualiza solo G. Los optimizadores referencian las redes ejecutadas. El generador aprende sin etiquetas de nombres ni clases.

Usamos Adam, tasa 0.0002 en ambas redes, betas 0.5 y 0.999, lote 32, semilla 42 y 2000 épocas. El orden de lotes y el ruido son independientes e idénticos entre condiciones. Ejecutamos en NVIDIA GeForce RTX 5050, Python 3.14.6 y PyTorch 2.13.0+cu130.

Referencias: Radford, Metz y Chintala, DCGAN (2015), arxiv.org/abs/1511.06434. Bengio, Léonard y Courville, estimadores de gradiente (2013), arxiv.org/abs/1308.3432.



Al generar imágenes nuevas no se actualizan los pesos.

Experimento de pérdida

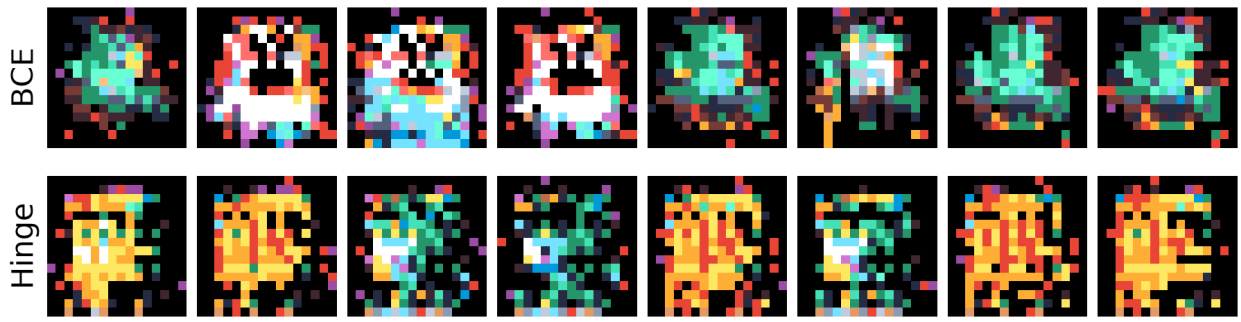
Hipótesis previa: Creemos que Hinge mejorará la estabilidad porque usa un margen en D y una pérdida lineal en G. Lo consideraremos útil si preserva diversidad y produce siluetas más claras con el mismo ruido fijo, sin aumentar similitud excesiva con entrenamiento.

BCE no saturante constituye el control. Hinge cambia exclusivamente la pérdida. Conservamos datos, arquitectura con paleta, inicialización, BatchNorm, optimizador, épocas, secuencias de lotes y ruido. Los hashes de los pesos iniciales coinciden. Las hipótesis quedaron guardadas antes de entrenar.

Para Hinge, D minimiza el promedio de max(0, 1 - D(real)) más max(0, 1 + D(falso)). G minimiza -promedio(D(falso)). BCE utiliza BCEWithLogitsLoss, con etiquetas reales para la pérdida de G. Las magnitudes de ambas funciones no son directamente comparables.

Condición	**Diversidad de 200 muestras**	**D media, 100 épocas hasta 1500**	**G media, 100 épocas hasta 1500**
BCE	0.385	0.000	11.444
Hinge	0.306	0.004	3.892

La figura compara ocho vectores fijos. Hinge repite figuras amarillas/verdes y su diversidad es menor que BCE; no observamos la mejora visual prevista. Ambas pérdidas muestran dominancia de D. Una diversidad mayor también puede ser ruido y no demuestra calidad por sí sola.



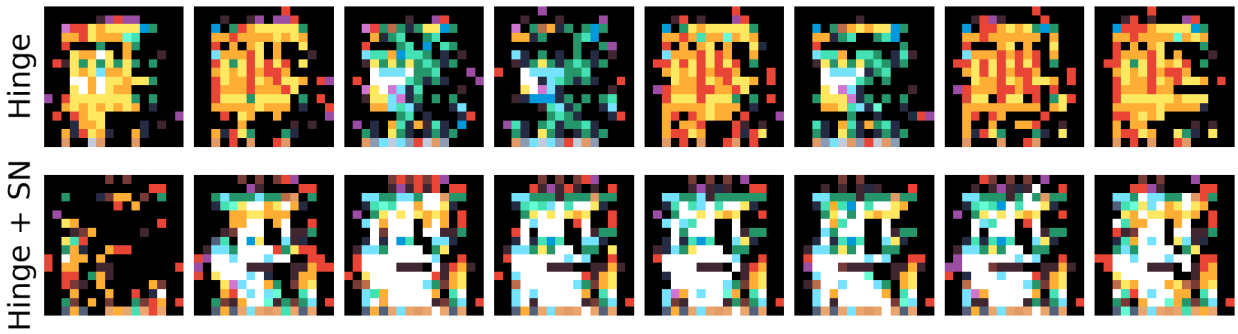
Experimento de estabilización

Hipótesis previa: Creemos que la normalización espectral mejorará porque limita la amplificación de las convoluciones de D. Lo consideraremos útil si mejora las muestras y evita dominancia prolongada de D frente al control Hinge.

El control usa Hinge sin normalización espectral. La variante aplica spectral_norm a las tres convoluciones de D. Conservamos BatchNorm, sesgos, arquitectura, pesos iniciales y todas las condiciones restantes. Así aislamos la normalización espectral, a diferencia del experimento histórico que también retiraba BatchNorm.

Condición	Diversidad	D media a 1500	G media a 1500
Hinge	0.306	0.004	3.892
Hinge + SN	0.363	0.008	3.116

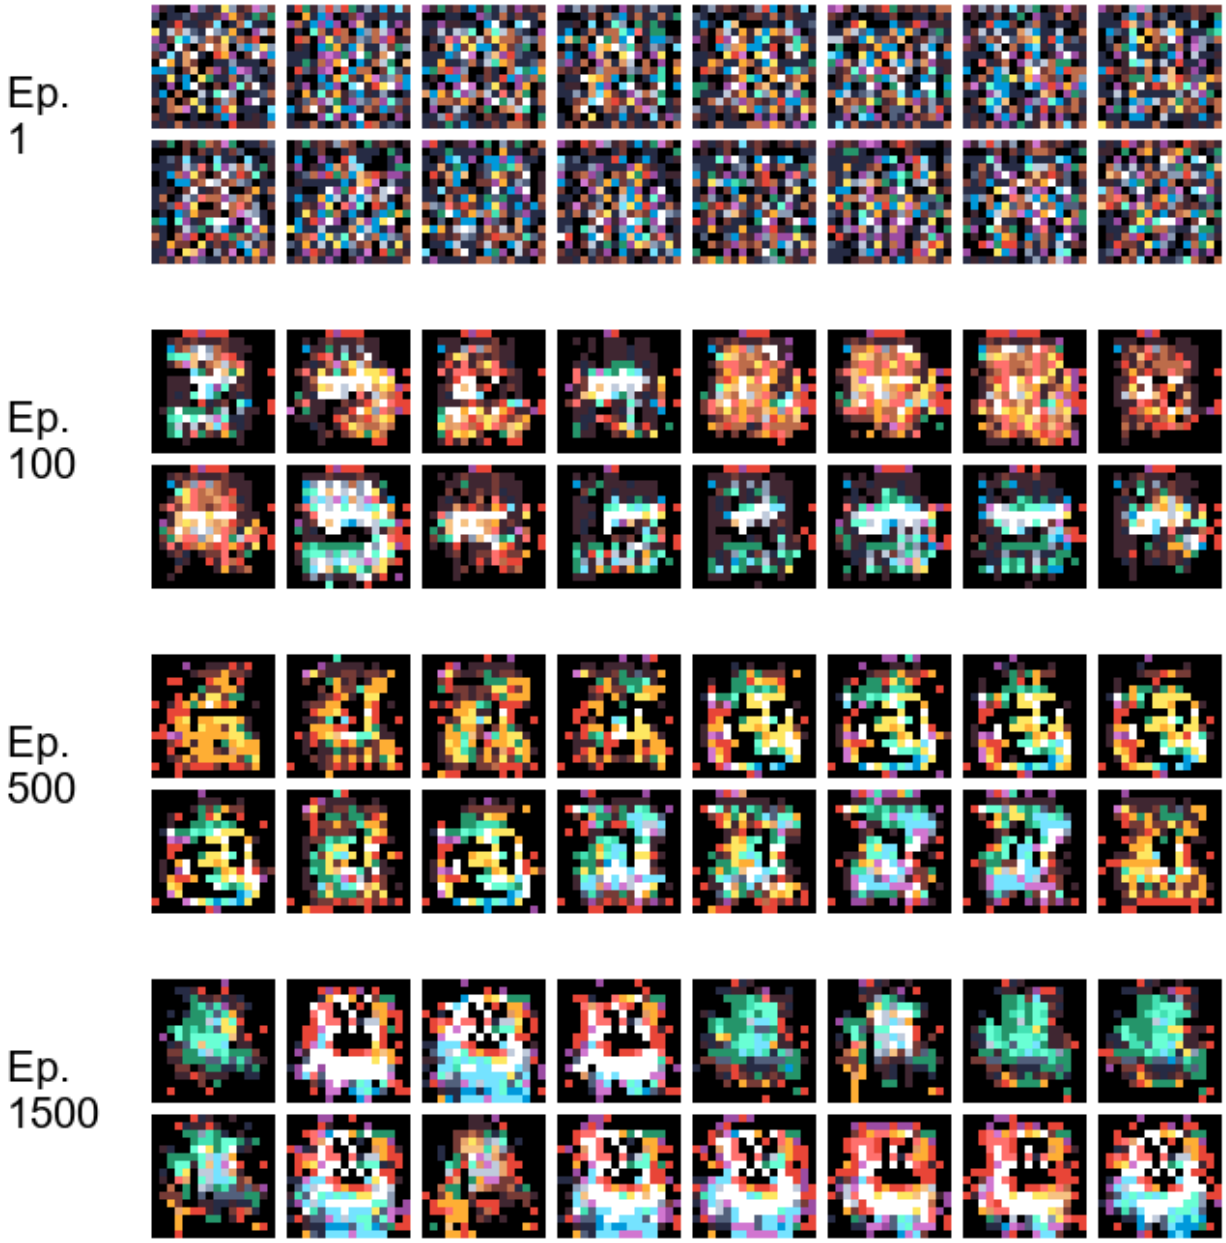
A época 1500, SN aumenta la diversidad en píxeles de 0.306 a 0.363 frente a Hinge. Sin embargo, varias muestras contienen bloques dispersos y fondos fragmentados. D permanece bajo 0.1 en 1952 de 2000 épocas, frente a 1950 del control. No encontramos evidencia de la mejora de estabilidad prevista; el incremento numérico de diversidad no basta para seleccionar SN.



Una pérdida de D cercana a cero durante muchas épocas indica separación fácil respecto al margen. Esa señal exige revisar muestras y diversidad. No prueba por sí sola memorización ni garantiza que G produzca personajes legibles. Referencia: Miyato et al., Spectral Normalization for GANs (2018), arxiv.org/abs/1802.05957.

Evolución con ruido fijo

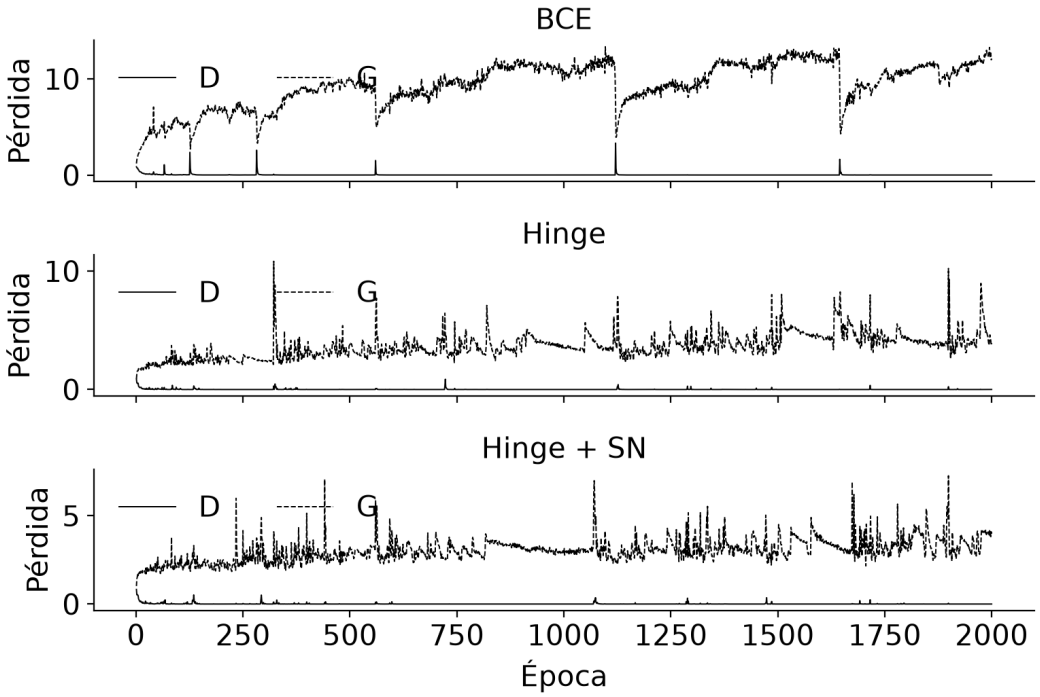
Seguimos los mismos 16 vectores z de semilla 123 en BCE. Cada evaluación recalibra una copia de G con 20 lotes de 128 vectores, semilla independiente 12345. Así no modifica el entrenamiento ni sus secuencias aleatorias. El checkpoint guarda las estadísticas usadas para generar.



Las columnas conservan sus vectores entre épocas. La repetición de siluetas dentro de una misma fila es una señal visual de pérdida de modos, aunque sus colores cambien.

Curvas de pérdida y problemas observados

Las curvas corresponden a corridas completas de una misma etapa. La línea continua representa D y la discontinua G. Sus escalas dependen de la función de pérdida, por lo que comparamos trayectorias dentro de cada condición y verificamos las imágenes.



Condición	Épocas con D menor que 0.1	D media a 1500	G media a 1500
BCE	1943 de 2000	0.000	11.444
Hinge	1950 de 2000	0.004	3.892
Hinge + SN	1952 de 2000	0.008	3.116

Las corridas RGB iniciales de 300 y 1500 épocas mantuvieron estructuras difusas y pérdidas compatibles con dominancia de D. Extender las épocas no solucionó esa limitación. Registramos entonces una nueva configuración con salida de paleta, compartida por las tres condiciones. Esa exploración cambia la arquitectura y no demuestra, por sí sola, un efecto causal aislado de la paleta.

La paleta evita colores intermedios, pero persisten anatomías ambiguas y repetición de arquetipos, compatibles con pérdida parcial de modos. Reducir la tasa de D bajó la diversidad final Hinge a 0.229; reducir sus canales a 16 la bajó a 0.185. Ninguna exploración justificó reemplazar el control. No interpretamos el error bajo de D como éxito.

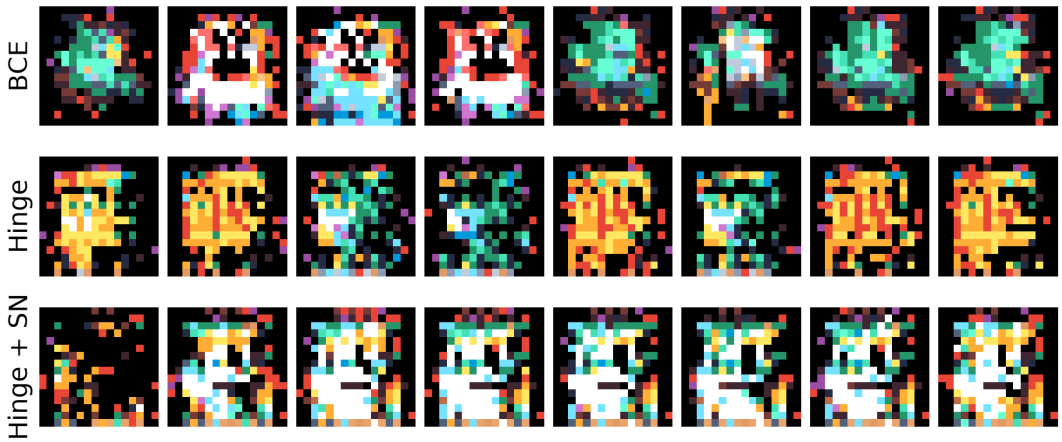
Evaluación y elección del modelo

Comparamos 200 candidatos por condición, con semillas 1000 a 1199 y checkpoint de época 1500. Medimos RMS sobre la rejilla nativa y similitud coseno en ResNet-18 preentrenada, con entrada NEAREST de 224 × 224. Los vecinos de entrenamiento incluyen originales y sus reflejos: 328 referencias.

Modelo	Diversidad	RMS a entrenamiento	RMS a validación	Coseno medio
BCE	0.385	0.291	0.309	0.942
Hinge	0.306	0.314	0.344	0.937
Hinge + SN	0.363	0.328	0.353	0.927

La diversidad de los originales de entrenamiento es 0.297 y la de validación 0.324. El tamaño y la composición de ambos conjuntos son distintos. Sus distancias a muestras generadas no constituyen una prueba concluyente de generalización.

Elegimos BCE, checkpoint 1500, por su mayor variedad relativa de siluetas y combinaciones visuales frente a Hinge y SN en las rejillas revisadas. Las tres redes entrenaron 2000 épocas, pero compararlas a 1500 mantiene el mismo punto de evaluación. Es una selección exploratoria: a 2000 BCE perdió diversidad (0.350 frente a 0.385) y no mejoró su legibilidad. La pérdida baja de D no se usó como criterio de éxito.

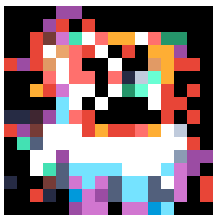


RMS favorece fondos y alineación compartidos. ResNet-18 procede de fotografías, por lo que puede agrupar por textura y color. La validación sirve para revisar y elegir el modelo, pero no hay un tercer conjunto de prueba. Una sola semilla por condición impide afirmar significación estadística o ausencia de sobreajuste.

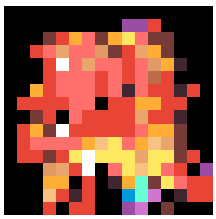
Galería final y criterio de selección

La galería usa BCE, época 1500. Seleccionamos 10 de 200 candidatos finales: 5%. En el desarrollo se generaron 2400 candidatos para evaluación con distintas redes y checkpoints: 10/2400 = 0.42%. Las semillas se repiten entre condiciones. Además inspeccionamos rejillas de ruido fijo. Revisamos silueta, forma, color, fondo y vecinos.

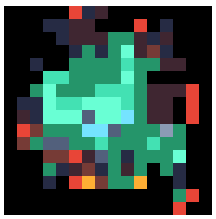
Cada PNG procede directamente del generador, con conversión a 8 bits. Los nombres y roles describen interpretaciones dentro del universo, no clases aprendidas por la red. Guardamos los diez vectores z y sus semillas para regenerar los conceptos.



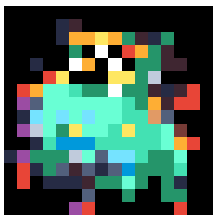
Morvath
Guardián
Seed 1000



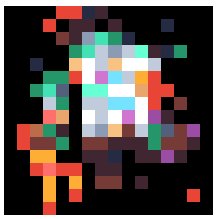
Ignis
Gólem ígneo
Seed 1008



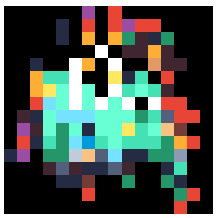
Mossgolem
Bestia de musgo
Seed 1020



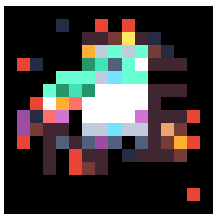
Glacius
Anfibio
Seed 1026



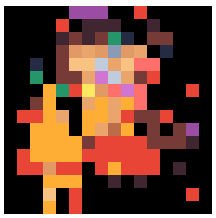
Kaelen
Hechicero
Seed 1035



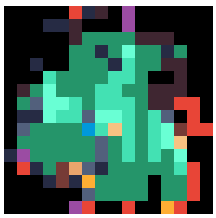
Zul Karr
Vigía
Seed 1070



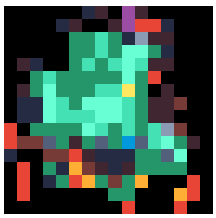
Fungor
Errante
Seed 1072



Brasa
Elemental
Seed 1017



Aveline
Espíritu
Seed 1114



Ursok
Bestia de cripta
Seed 1171

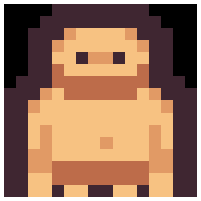
La curación conserva figuras compactas, otras alargadas y algunas con apéndices laterales. Sus colores y proporciones varían, pero varias pertenecen a arquetipos verdes parecidos y la anatomía sigue siendo ambigua. La menor RMS entre los diez es 0.204; esa separación de píxeles no garantiza diez identidades semánticas distintas. Los resultados son conceptos experimentales, no sprites terminados.

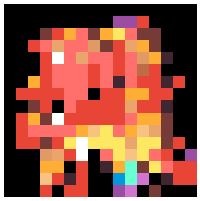
La comprobación reprodujo los diez personajes con error máximo 0.00000001, menor que 2/255. Los vectores coinciden con sus semillas. Fijamos CPU y lote 1 para exportar: una primera prueba desde GPU cambió un píxel por argmax cerca de un empate. Conservamos el registro de ese fallo y la verificación corregida.

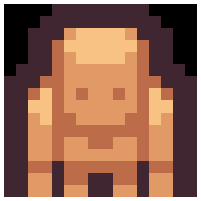
Vecinos más cercanos de los diez personajes

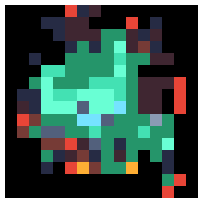
Para cada personaje mostramos su vecino de entrenamiento con menor RMS, considerando originales y reflejos. Esta comparación permite inspeccionar copia y semejanza estructural. Una distancia distinta de cero no demuestra originalidad semántica.

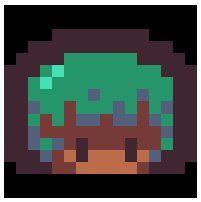

Generado 01

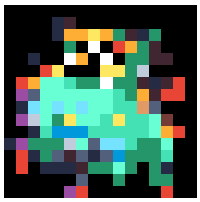

RMS 0.373

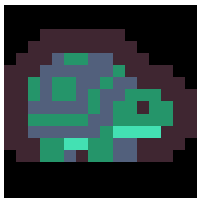

Generado 02

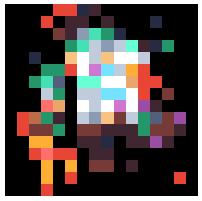

RMS 0.273


Generado 03

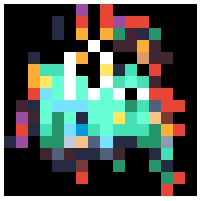

RMS 0.225

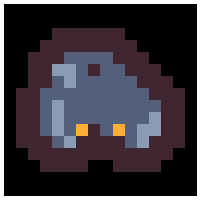

Generado 04


RMS 0.288


Generado 05

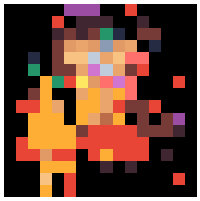

RMS 0.264

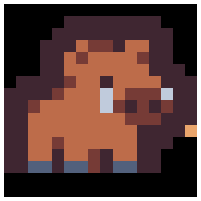

Generado 06

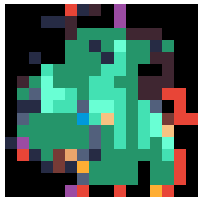

RMS 0.294


Generado 07

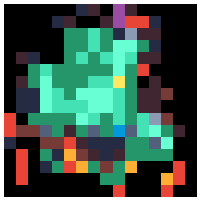

RMS 0.256

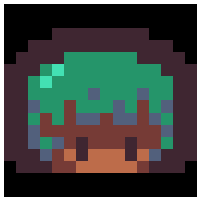

Generado 08


RMS 0.259


Generado 09


RMS 0.240


Generado 10


RMS 0.256

Reflexión final, limitaciones y reproducción

Aveline, personaje 09 (seed 1114), fue el más difícil de defender. Su vecino por ResNet es creatures_0111, con coseno 0.977; por RMS es creatures_0099 reflejado, con distancia 0.240. Conserva un cuerpo verde y apéndices que recuerdan formas del dataset. El parecido y la textura compartida impiden afirmar novedad solo con métricas. Este caso sugiere recombinación de colores y siluetas del universo, con detalles todavía poco legibles, y exige más datos y pruebas para defender una identidad nueva.



La selección manual y la paleta favorecen coherencia visual, pero no prueban que cada resultado sea un personaje completamente nuevo. Los datos incluyen solo 164 originales de entrenamiento y contienen familias relacionadas. La red todavía puede omitir extremidades, repetir arquetipos o producir proporciones extrañas. No afirmamos ausencia de memorización a partir de una sola métrica.

El paquete incluye los 312 originales, selección y separación, paleta de entrenamiento, configuraciones, hipótesis previas, historiales, figuras, pesos y galería. Ejecutar generar.py --verificar comprueba la regeneración. prepare_data.py reconstruye el dataset; el notebook y README detallan las tres corridas y la evaluación.

Usamos asistentes de IA para revisar código, depurar datos, ejecutar verificaciones y redactar el informe. Todas las imágenes generadas provienen de las redes de este proyecto. Conservamos las corridas exploratorias y sus resultados como límites de la investigación.

Fundamento adversarial: Goodfellow et al., Generative Adversarial Networks (2014), arxiv.org/abs/1406.2661. Las referencias de datos, arquitectura y estabilización aparecen junto a sus respectivos análisis.

Matriz de evidencias

La matriz vincula cada requisito con su evidencia, la conclusión que permite sostener y su principal limitación.

Evidencia	Página	Conclusión	Limitación
Universo y fuentes	1	Estilo definido y fuentes CC0 documentadas.	Coherencia visual evaluada de forma cualitativa.
Depuración y separación	2	199 sprites, 164/35 y familias separadas antes del aumento.	El agrupamiento puede omitir relaciones visuales.
Arquitectura funcional	3	DCGAN con salida de paleta y exportación 64 × 64.	Gradiente sustituto aproximado y pocos datos.
Pérdida BCE frente a Hinge	4	Comparación con una sola variable modificada.	Una semilla y pérdidas con escalas distintas.
Normalización espectral	5	Comparación Hinge/SN conservando BatchNorm.	El resultado depende de esta arquitectura.
Ruido fijo y curvas	6, 7	Evolución de 16 vectores y dinámica documentadas.	Muestras y pérdidas no prueban generalización.
Evaluación y elección	8	Decisión basada en imágenes y varias medidas.	Validación usada para elegir, sin prueba independiente.
Galería regenerable	9	10/200, vectores y semillas verificados en CPU.	Curación manual y calidad visual limitada.
Vecinos y reflexión	10, 11	Cada personaje tiene un vecino inspeccionable.	RMS y ResNet tienen sesgos de fondo y textura.

Los manifiestos y archivos JSON contienen las cifras completas. El informe distingue las observaciones de las hipótesis y conserva las limitaciones que afectan la interpretación de los resultados.